# Báo Cáo Chi Tiết Công Việc Đã Thực Hiện

Phân hệ B1: Data Cleaning, Structure-aware Chunking & Ingestion Pipeline

## 1. Nhiệm Vụ Được Giao

Tiếp nhận yêu cầu từ người dùng: "sau khi có dataset thì làm sao clean" và "hãy clean và chunk cho tôi". Trước thời điểm thực hiện, toàn bộ 4 file nghiệp vụ của Module B1 (Document Intelligence) đều ở trạng thái scaffold rỗng (chưa có code logic), và 54 file tài liệu DSA trong data/corpus/dataset_raw chưa qua xử lý.

## 2. Các Module Đã Lập Trình Hoàn Chỉnh

| Tệp nguồn (File Path) | Trạng thái | Logic kỹ thuật đã hiện thực |
|---|---|---|
| backend/app/document_processing/document_parser.py | **Hoàn thành** | Trích xuất text theo từng trang cho PDF bằng PyMuPDF (fitz) và text theo Heading 1 cho python-docx. Chuẩn hóa cấu trúc trung gian PageText(page, raw_text, file_type). |
| backend/app/document_processing/text_cleaner.py | **Hoàn thành** | • Chuẩn hóa Unicode NFC (xử lý triệt để lỗi gõ tiếng Việt tổ hợp).<br>• Lọc bỏ ký tự điều khiển ASCII, font bullet lạ.<br>• Tự động nối từ bị ngắt dòng do gạch nối (struc-\nture → structure).<br>• Loại bỏ Header/Footer, số trang lặp lại bằng Regex.<br>• Hàm kiểm tra chất lượng chunk (QA Gate): is_valid_chunk_text() loại bỏ rác/nhiễu. |
| backend/app/document_processing/chunker.py | **Hoàn thành** | Thuật toán chia đoạn đệ quy theo ngữ cảnh (Recursive Splitting): Kích thước chunk mặc định 512 ký tự, độ chồng lấp (overlap) 100 ký tự. Tự động trích xuất tiêu đề mục (section header) để bảo tồn ngữ cảnh DSA. |
| backend/app/document_processing/metadata.py | **Hoàn thành** | Đóng gói thành đối tượng DocumentChunk theo chuẩn Data Contract của Team B → Team C. Tự động sinh mã chunk_id băm SHA-1 độc bản, slug hóa tên tài liệu document_id và gắn metadata ngôn ngữ. |
| data/corpus/run_pipeline.py | **Hoàn thành** | Script vận hành tự động toàn bộ pipeline xử lý hàng loạt: Quét đệ quy thư mục raw → Parse → Detect language → Clean → Chunk → Validate → Xuất kết quả ra file JSON Lines và file báo cáo JSON. |

## 3. Kết Quả Thực Thi Thực Tế Trên Toàn Bộ Dataset

Đã thực thi thành công script run_pipeline.py trên toàn bộ 54 file tài liệu raw DSA. Kết quả đạt tỷ lệ chính xác tuyệt đối không gặp lỗi:

| Chỉ số đo lường | Kết quả thực tế | Ghi chú phân tích |
|---|---|---|
| **Tổng số file đưa vào** | 54 / 54 files | Toàn bộ dataset PDF & DOCX hiện có trong thư mục corpus |
| **Tỷ lệ xử lý thành công** | 100% (0 lỗi) | Tất cả tài liệu đều được parse và clean trơn tru |
| **Tổng số Chunks hợp lệ** | 5,941 chunks | Đã qua QA Gate loại bỏ các chunk rác hoặc quá ngắn (<15 từ) |
| **Thời gian thực thi toàn bộ** | 21.31 giây | Tốc độ trung bình ~0.39 giây/file tài liệu |

**Chi tiết phân bổ chunks theo danh mục tài liệu:**

| Thư mục con (Folder) | Số lượng file | Số chunk sinh ra | Đặc điểm nội dung tài liệu |
|---|---|---|---|

| | | | |
|---|---|---|---|
| docx_Files/end_docx | 6 files | **31 chunks** | Tài liệu tóm tắt lý thuyết DSA ngắn bằng Tiếng Anh |
| docx_Files/vie_docx | 7 files | **175 chunks** | Bài tập và giáo trình Tiếng Việt (file 002 lớn nhất: 141 chunks) |
| pdf_Files/eng_pdf | 20 files | **491 chunks** | Slide bài giảng các cấu trúc dữ liệu cơ bản bằng Tiếng Anh |
| pdf_Files/vie_pdf | 21 files | **5,244 chunks** | Bộ giáo trình và chuyên đề chuyên sâu DSA Tiếng Việt (dung lượng lớn) |
| **TỔNG CỘNG** | **54 files** | **5,941 chunks** | **Đầy đủ ngữ cảnh sẵn sàng cho Vector Indexing** |

## 4. Sản Phẩm Bàn Giao Kỹ Thuật

 File dữ liệu Chunks hoàn chỉnh: data/corpus/dataset_clean/chunks_all.jsonl chứa toàn bộ 5,941 chunks chuẩn cấu trúc Pydantic DocumentChunk (sẵn sàng nạp trực tiếp vào Qdrant và BM25).

 Báo cáo thống kê chi tiết: data/corpus/dataset_clean/pipeline_report.json ghi lại chính xác số chunk, trạng thái xử lý từng file và thời gian chạy.

 Nhật ký log thực thi: data/corpus/dataset_clean/pipeline.log lưu vết quá trình thực thi chi tiết phục vụ kiểm tra và gỡ lỗi.

 Tiền trạm Module C1: Đã chuẩn bị sẵn các hàm khởi tạo và cấu hình Qdrant local embedding trong backend/app/retrieval/ để Team C tiếp nhận dữ liệu ngay lập tức.