DSA Document Assistant Using Hybrid RAG

Hồ Sơ Kỹ Thuật Toàn Diện & Thiết Kế Hệ Thống — Track C (Intelligent Document Workspace)

1. Tổng Quan & Mục Tiêu Dự Án

DSA Document Assistant là giải pháp trợ lý học tập và ôn luyện chuyên sâu cho môn Cấu trúc Dữ liệu và Giải thuật (Data Structures & Algorithms - DSA). Hệ thống kết hợp kỹ thuật Hybrid RAG (Dense Semantic Retrieval + Sparse BM25 Keyword Search), giải quyết triệt để vấn đề ảo giác (hallucination) của LLM bằng việc bắt buộc trích dẫn bằng chứng (Citations) chính xác đến từng trang tài liệu / slide học phần, đồng thời tích hợp cơ chế Guardrail an toàn.

Hạng mục	Mô tả chi tiết
Tên đề tài	Trợ lý Học tập & Ôn thi môn DSA sử dụng Hybrid RAG
Phạm vi tài liệu	Slide bài giảng, giáo trình, bài tập lý thuyết & thực hành DSA (Tiếng Việt & Tiếng Anh)
Kiến trúc cốt lõi	Hybrid RAG = Qdrant Vector Search (Dense) + BM25 (Sparse) + Reciprocal Rank Fusion (RRF)
Mô hình & AI	Embeddings đa ngữ (sentence-transformers) + LLM tạo câu trả lời, câu hỏi trắc nghiệm & lộ trình ôn tập
Giao diện & API	FastAPI Backend (REST API Port 8000) + Streamlit Frontend UI (Port 8501)
Tính năng nổi bật	Hỏi đáp trích dẫn (Citations), Luyện trắc nghiệm (Quiz), Lộ trình ôn tập (Revision Plan), Kiểm duyệt an toàn (Guardrail)

2. Kiến Trúc Kỹ Thuật Tổng Thể (End-to-End Architecture)

Hệ thống vận hành theo quy trình khép kín gồm 4 phân tầng kiến trúc chính:

- Tầng 1 — Client & Presentation (A2): Streamlit UI gồm 4 phân hệ chính: Trò chuyện & Hỏi đáp (Chat UI), Tải lên tài liệu (Upload UI), Luyện tập trắc nghiệm (Quiz UI), Lộ trình ôn tập (Revision UI). Giám sát trạng thái Backend theo thời gian thực.
- Tầng 2 — API Gateway & Điều phối (A1, A3): FastAPI Backend tiếp nhận HTTP requests, xử lý tiền kiểm tra file tải lên, điều hướng intent, đo lường độ trễ (X-Process-Time-MS), định cấu hình tập trung qua .env.
- Tầng 3 — Xử lý Tài liệu & Chỉ mục (B1, C1): Document Parser (PDF/DOCX) → Text Cleaner (lọc nhiễu, chuẩn hóa NFC) → Structure-aware Chunker (chia đoạn 512 ký tự) → Provenance Metadata → Lưu trữ vào Qdrant (Dense + Sparse).
- Tầng 4 — Hybrid Retrieval, RAG & Safety (C1, C2, D2): Nhận câu hỏi → Guardrail thẩm tra an toàn → Truy vấn Hybrid Search kết hợp BM25 & Vector → Reranker → Prompt Context → LLM sinh câu trả lời kèm Citation có căn cứ.

3. Cơ Cấu Tổ Chức & Phân Công Trách Nhiệm Nhóm

Mã	Thành viên	Vai trò chính	Nhiệm vụ trọng tâm trong dự án
A1	Nguyễn Lê Phú Trọng	Backend & Điều phối	Dựng FastAPI Gateway, định nghĩa Endpoint `/health`, `/api/chat`, `/api/upload`
A2	Nguyễn Văn An	Frontend & UI/UX	Xây dựng Streamlit 4 màn hình, Client API, hiển thị Citation, Quiz UI, Revision UI
A3	Nguyễn Phú Nguyên Vũ	Hạ tầng & DevOps	Thiết lập môi trường `.venv`, `requirements.txt`, Docker Compose, `.vscode` Task/Launch
B1	Nguyễn Thanh Danh	Document Intelligence	Phát triển Document Parser (PDF/DOCX), Text Cleaner, Chunker, Metadata Extraction
C1	Trương Minh Quân	Retrieval & VectorDB	Thiết lập Qdrant DB, xây dựng Hybrid Search (BM25 sparse + Dense Vector) & Reranker
C2	Hứa Kiến Quốc	RAG & Generation	LLM Client, RAG Engine, trích dẫn Citation, Quiz Generator, Revision Plan Generator
D1	Đặng Phan Gia Bảo	Evaluation & Benchmark	Thu thập Corpus DSA chuẩn, xây dựng bộ Ground-truth, đánh giá RAG Triad
D2	Nguyễn Minh Cường	Safety & Reliability	Xây dựng Guardrail phòng chống Prompt Injection, kiểm duyệt nội dung an toàn

4. Chuẩn Giao Tiếp Dữ Liệu (Data Contracts)

Các module được cô lập chặt chẽ thông qua các hợp đồng Pydantic Schema tại backend/app/schemas/contracts.py:

Hợp đồng (Contract)	Chiều giao tiếp	Các trường dữ liệu then chốt	Mục đích sử dụng
DocumentChunk	**B1 → C1**	chunk_id, document_id, filename, page, section, text, metadata	Đơn vị dữ liệu chuẩn hóa để nạp vào chỉ mục Vector DB và BM25
Citation	**C2 → Frontend**	filename, page, section, snippet	Minh chứng nguồn gốc cụ thể để người học đối soát thông tin
RAGResponse	**C2 → A1 → A2**	query, answer, citations, confidence_score, is_safe	Gói dữ liệu phản hồi hoàn chỉnh trả về giao diện người dùng
GuardrailResult	**D2 → A1/C2**	is_safe, risk_category, refusal_message	Quyết định cho phép xử lý tiếp hay chặn phản hồi vì lý do an toàn

5. Kế Hoạch & Lộ Trình Triển Khai (Project Milestones)

 Mốc Tuần 4 (Đã hoàn thành): Dựng khung hạ tầng Backend/Frontend PoC, thống nhất Data Contracts, hoàn thiện cấu hình `.env`, `requirements.txt`, Docker Compose, `.vscode` tích hợp.

 Mốc Tuần 5 - 6 (Hiện tại): Hoàn thiện toàn bộ pipeline Data Ingestion & Cleaning (Module B1), nạp chỉ mục Hybrid Vector DB Qdrant (Module C1), chuẩn bị dữ liệu Benchmark DSA (Module D1).

 Mốc Tuần 7: Tích hợp Core RAG Engine (C2), Generator sinh trắc nghiệm tự động & lộ trình ôn tập, áp dụng Guardrail (D2) và kết nối thông suốt lên giao diện Streamlit (A2).

 Mốc Tuần 8 - 10: Đánh giá chất lượng RAG Triad (Context Precision, Faithfulness, Answer Relevance), tinh chỉnh Prompt & Re-ranking, thử nghiệm tải cao.

 Mốc Tuần 11: Đóng gói hoàn chỉnh hệ thống, báo cáo nghiệm thu và bảo vệ đồ án.